

Reconhecimento de emoções faciais em imagens utilizando métodos clássicos de aprendizagem de máquina

Rafael Lelis Ferrari

¹Programa de Pós Graduação em Computação Aplicada

²Instituto Federal do Espírito Santo - Campus Serra
Rodovia ES-010 - Km 6,5 - Manguinhos, Serra, ES, Brasil

rlelisferrari@gmail.com

Abstract. *In this work classic machine learning methods were used to perform the recognition angry and happy emotion in images from The Radboud Faces Database (RaFD). The Viola-Jones algorithm was used to detect the face and extract the regions of the eyes and mouth. As feature extractor we used the descriptor Local Binary Patterns (LBP). The metric used to measure the performance of classifiers was the accuracy. The results show that the Linear Support Vector Machines (SVM) classifier is very effective in detecting angry and happy emotions.*

Resumo. *Neste trabalho foram utilizados métodos clássicos de aprendizagem de máquina para realizar o reconhecimento da emoção raiva e alegria em imagens da base de dados The Radboud Faces Database (RaFD). Utilizou-se o algoritmo Viola-Jones para detectar a face e extrair da imagem as regiões dos olhos e da boca. Como extrator de características foi utilizado o descritor Padrões Binários Locais (LBP). A métrica utilizada para medir o desempenho dos classificadores foi a acurácia. Os resultados mostram que o classificador Máquinas de Vetores de Suporte (SVM) linear é bastante eficaz na detecção das emoções raiva e alegria.*

1. Introdução

Na área de reconhecimento de emoções em faces existem vários trabalhos, destacando-se o trabalho de [dos Santos Paiva et al.] que apresentou 94% de exatidão utilizando o descritor LBP e o classificador SVM. No presente trabalho também utilizou-se o extrator de características LBP e os classificadores *AdaBoost*, *Decision Tree*, *Gaussian Processes*, *KNN (K-Nearest Neighbor)*, *Linear SVM*, *Naive Bayes*, *MLP (Multi-layer Perceptron)*, *QDA (Quadratic Discriminant Analysis)*, *Random Forest* e o *RBF SVM (Radial Basis Function kernel)* para detectar emoções em imagens.

Na arquitetura clássica de aprendizagem de máquina a classificação ocorre em duas fases, a fase de treinamento (*Training Phase*) e a fase de predição (*Prediction Phase*), conforme ilustra a Figura 1. Desta forma a proposta do trabalho é utilizar essa abordagem clássica para treinar e testar os classificadores citados para realizarem o reconhecimento da emoção raiva e alegria em imagens da base de dados RaFD.

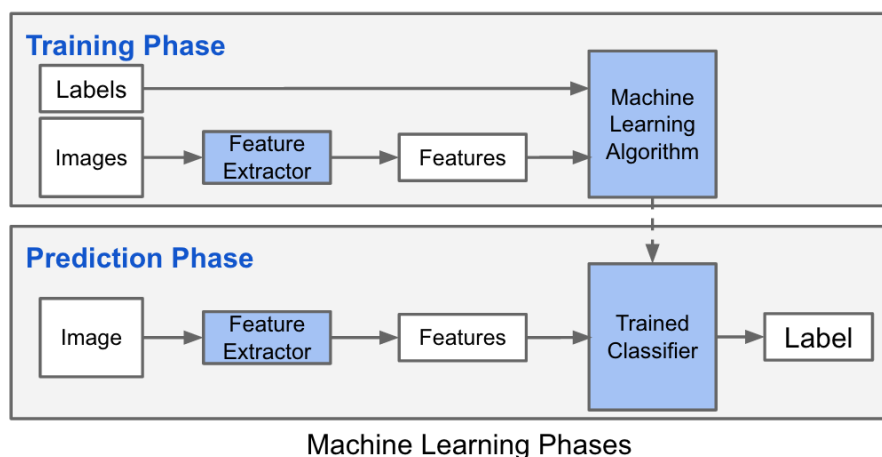


Figure 1. Fases da arquitetura clássica de aprendizagem de máquina
[Moujahid 2016]

2. Abordagem Proposta

Tanto na fase de treinamento como na fase de predição dos classificadores o algoritmo construído realiza uma rotina de extração de características sobre as imagens antes de efetivamente treinar e testar o modelo. Essa rotina é dividida nas seguintes etapas: Pré-processamento da imagem (converte a imagem em escala de cinza), detecção da face na imagem e extração das regiões de interesse da face utilizando o algoritmo Viola-Jones e a extração do vetor de características das regiões de interesse utilizando o descritor LBP.

A primeira rotina que o sistema executa é carregar todas as imagens destinadas ao treinamento dos modelos e aplicar a rotina de extração de características. O resultado dessa rotina é uma estrutura que contém o vetor de características da imagem vinculado ao seu rótulo. A segunda rotina executada pelo sistema corresponde ao treinamento dos modelos utilizando a estrutura gerada na rotina anterior. Uma terceira rotina é responsável por carregar as imagens destinadas aos testes dos modelos e novamente aplicar a rotina de extração de características. Finalmente, o conjunto dos vetores de características obtidos são utilizadas em uma quarta rotina para testar os modelos treinados e fazer a predição das imagens.

3. Resultados

Para medir o desempenho dos classificadores foi utilizada a métrica acurácia que corresponde ao número de acertos dividido pelo número total de exemplos. Foram utilizados 402 imagens da base RaFD incluindo homens, mulheres e crianças caucasianos, de ambos os sexos, e homens holandeses de etnia marroquina, demonstrando as emoções faciais raiva e alegria. Foi utilizada a técnica de *Hold-Out* sendo que 70% das imagens (282) foram utilizadas para treinar os modelos e 30% delas (120) para testá-los. A Tabela 1 e a Tabela 2 mostram o desempenho de cada classificador ordenado por maior acurácia no reconhecimento da raiva e da alegria, respectivamente.

Observa-se que o classificador *Linear SVM* apresentou o maior desempenho no reconhecimento da emoção raiva com 93.3% de acurácia e um ótimo desempenho no reconhecimento da emoção alegria (91.7%), só ficando atrás do método *AdaBoost* que

obteve 93.3% de acurácia do reconhecimento da emoção alegria, porém não foi bem no reconhecimento da emoção raiva com apenas 66.7% de acurácia.

Os classificadores *Random Forest*, *Gaussian Processes*, *Decision Tree* e QDA também apresentaram um bom desempenho no reconhecimento da emoção alegria, obtendo respectivamente 86.7%, 85%, 85% e 76.7% de acurácia. Ainda no reconhecimento da emoção raiva cita-se os métodos *Gaussian Processes*, QDA e *Naive Bayes* com um desempenho moderado de 73.3%, 71.7% e 70% de acurácia, respectivamente. Os classificadores MLP, KNN e RBF SVM não apresentaram um bom desempenho obtendo acurácia inferior a 70% para ambas emoções.

Table 1. Desempenho dos classificadores em reconhecer as emoções raiva e alegria (ordenados por maior acurácia no reconhecimento da raiva).

Classificadores	Raiva	Alegria
Linear SVM	93.3%	91.7%
Gaussian Processes	73.3%	85.0%
QDA	71.7%	76.7%
Naive Bayes	70.0%	33.3%
MLP	68.3%	65.0%
AdaBoost	66.7%	93.3%
KNN	61.7%	68.3%
Decision Tree	56.7%	85.0%
Random Forest	46.7%	86.7%
RBF SVM	43.3%	66.7%

Table 2. Desempenho dos classificadores em reconhecer as emoções raiva e alegria (ordenados por maior acurácia no reconhecimento da alegria).

Classificadores	Raiva	Alegria
AdaBoost	66.7%	93.3%
Linear SVM	93.3%	91.7%
Random Forest	46.7%	86.7%
Gaussian Processes	73.3%	85.0%
Decision Tree	56.7%	85.0%
QDA	71.7%	76.7%
KNN	61.7%	68.3%
RBF SVM	43.3%	66.7%
MLP	68.3%	65.0%
Naive Bayes	70.0%	33.3%

4. Considerações Finais

No presente trabalho foi apresentado um sistema de reconhecimento de emoções faciais em imagens utilizando uma arquitetura clássica de aprendizagem de máquina, onde os principais métodos clássicos foram treinados e testados afim de reconhecerem a emoção raiva e alegria. Dentre os métodos destacou-se o *Linear SVM* no reconhecimento de ambas emoções e o método *AdaBoost* no reconhecimento da emoção alegria.

5. Referências

References

dos Santos Paiva, F. A., Costa, P. D. P., and De Martino, J. M. Supervised methods for classifying facial emotions.

Moujahid, A. (2016). A practical introduction to deep learning with caffe and python. *Retrieved February, 19:2018.*